

Problem Set 1

José Manuel Muñoz Carrillo A01595143, Marco Méndez Atienza A01330601

Part 1 (20 points)

1) Problema de minimización

- Dado que el modelo es $y_i = \alpha + \varepsilon_i$, entonces los residuales son $\varepsilon_i = y_i - \alpha$. Elevando al cuadrado y obteniendo su suma:

$$SSR = \sum_{i=1}^n (y_i - \alpha)^2 \quad \text{donde SSR: sum of squared residuals}$$

- Por lo que el objetivo es:

$$\min_{\alpha} \sum_{i=1}^n (y_i - \alpha)^2$$

2) Resolver para $\hat{\alpha}$

- Condición de 1er orden:

$$\frac{d}{d\alpha} \sum_{i=1}^n (y_i - \alpha)^2 = 0$$

$$\Rightarrow \sum_{i=1}^n 2(y_i - \alpha)(-1) = 0$$

$$\Rightarrow \sum_{i=1}^n (y_i - \alpha) = 0$$

$$\Rightarrow \sum_{i=1}^n y_i - \sum_{i=1}^n \alpha = 0$$

$$\Rightarrow \sum_{i=1}^n y_i - n\alpha = 0$$

- Se resuelve para el estimador de α , $\hat{\alpha}$:

$$n\hat{\alpha} = \sum_{i=1}^n y_i$$

$$\therefore \hat{\alpha} = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}$$

- Este resultado indica que si nuestra variable de interés y solo está determinada por una constante + ruido aleatorio, la MEJOR predicción que minimiza los residuales es solamente el promedio de los datos observados.

Part 2 (10 points)

- 1) Falso: Si bien las regresiones por MCO pueden incluir muchos controles, no “arregla” la maldición de la dimensionalidad, sino que lo evita con el supuesto de que la relación entre variables es lineal. Pero si este supuesto es incorrecto, los estimadores estarían sesgados aunque se cumpla la no selección en no observables.
- 2) Falso: El Efecto de Tratamiento a nivel individual se define como la diferencia en resultados potenciales $y_i(1) - y_i(0)$. El Average Treatment Effect (ATE), por su parte, sí identifica la diferencia en resultados promedio entre grupo control y tratamiento
- 3) Verdadero
- 4) Falso: El Teorema del Límite Central (TLC) establece que, mientras el tamaño de muestra crece, la media muestral converge APROXIMADAMENTE a una distribución normal
- 5) Verdadero

Part 3 (10 points)

- a) El coeficiente $\hat{\beta}_1 = -2.0$ representa que, en promedio, las mujeres ganan \$2 menos que los hombres, que son el grupo base
- b) Lo más probable es que no haya selection on observables. Esto porque aunque estamos observando la educación, existen factores no observados (por ejemplo, experiencia laboral, tipo de industrias, habilidades de cada persona) que afectan el salario y también están correlacionados con género; esto introducirá sesgos en las estimaciones
- c) Al agregar educación, probablemente disminuya el error estándar, dado que la educación seguramente explica en gran medida el salario -> lo que reduce la varianza σ^2 del modelo. El SE podría subir solo si la educación está muy correlacionada con género (que sería además un problema de multicolinealidad).

Part 4 (30 points)

For this section questions use the dataset smoking2.dta (available on Canvas). This is a dataset comprised of birth certificate records. It contains information on infant health, demographic characteristics of the parents, pre-natal care use, and health risks factors.

1. Suppose your goal was to determine the impact of smoking during pregnancy on a measure of infant health, birthweight.

a. Compare the average birthweight (i.e. dbirwt) of children born to smokers and non-smokers (i.e. tobacco). Is the mean difference “significant” in a statistical sense?

```
## # A tibble: 2 x 4
##   tobacco      n mean_birthweight sd_birthweight
##   <dbl> <int>          <dbl>          <dbl>
## 1      0 113175          3426.            570.
## 2      1 25974          3168.            582.

##
## Welch Two Sample t-test
##
## data: dbirwt by tobacco
## t = 64.562, df = 38264, p-value < 2.2e-16
## alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
## 95 percent confidence interval:
##  249.7528 265.3920
## sample estimates:
## mean in group 0 mean in group 1
##      3425.556      3167.984
```

La diferencia de medias es estadísticamente significativa. Los resultados muestran que los hijos de madres no fumadoras (grupo 0) tienen un peso promedio al nacer de 3,425.56 gramos, mientras que los hijos de madres fumadoras (grupo 1) promedian 3,167.98 gramos.

Existe una diferencia de aproximadamente 257.57 gramos en los hijos de fumadoras. El valor p es menor a 0.05, lo que nos permite rechazar la hipótesis nula de igualdad de medias con un nivel de confianza superior al 95%. El intervalo de confianza del 95% para la diferencia (entre 249.75 y 265.39 gramos) no incluye el cero, lo que confirma la significancia estadística.

b. Test for “selection on observables”. Remember to check whether both conditions of selection on observables are met. What does this suggest about the results from (a) being a valid causal estimate of the effect of smoking on birthweight?

```
##           variable mean_nonsmoker mean_smoker difference
## mean in group 0    dimage  27.232666225 25.367829368  1.864836857
## mean in group 01   dmeduc  13.123861277 11.870832371  1.253028906
## mean in group 02    dmar    0.179969074  0.413605914 -0.233636839
## mean in group 03   dlivord   1.931866578  2.098868099 -0.167001521
## mean in group 04  nprevist  11.164683013 10.251636252  0.913046761
## mean in group 05   disllb  24.538007510 29.404519905 -4.866512394
## mean in group 06    dfage  29.535383256 28.354508355  1.180874902
## mean in group 07   dfeduc  13.253775127 12.037537538  1.216237589
## mean in group 08   anemia   0.009843163  0.018018018 -0.008174855
## mean in group 09   diabete   0.016823503  0.015169015  0.001654488
## mean in group 010  phyper    0.030678153  0.019635020  0.011043134
## mean in group 011  pre4000   0.012856196  0.006545007  0.006311190
## mean in group 012  preterm   0.012670643  0.028374528 -0.015703886
## mean in group 013  alcohol   0.008517782  0.051590052 -0.043072269
## mean in group 014   drink    0.018396289  0.183606684 -0.165210395
```

```
## mean in group 015 foreignb 0.050337972 0.016863017 0.033474955
## mean in group 016 plural 0.015939916 0.013436513 0.002503403
## mean in group 017 mblack 0.109520654 0.138985139 -0.029464485
## mean in group 018 motherr 0.016929534 0.003696004 0.013233530
## mean in group 019 mhispan 0.026242545 0.016940017 0.009302528
## mean in group 020 fblack 0.115953170 0.153884654 -0.037931484
## mean in group 021 fotherr 0.015772034 0.003195503 0.012576531
## mean in group 022 fhispan 0.027824166 0.023331023 0.004493143
##
## p_value significant
## mean in group 0 0.000000e+00 Yes
## mean in group 01 0.000000e+00 Yes
## mean in group 02 0.000000e+00 Yes
## mean in group 03 2.946274e-90 Yes
## mean in group 04 1.072486e-250 Yes
## mean in group 05 1.631291e-84 Yes
## mean in group 06 2.055535e-154 Yes
## mean in group 07 0.000000e+00 Yes
## mean in group 08 1.099428e-20 Yes
## mean in group 09 5.141643e-02 No
## mean in group 010 3.255340e-28 Yes
## mean in group 011 1.101455e-25 Yes
## mean in group 012 1.582543e-47 Yes
## mean in group 013 1.300775e-204 Yes
## mean in group 014 5.261057e-93 Yes
## mean in group 015 6.725218e-230 Yes
## mean in group 016 1.887786e-03 Yes
## mean in group 017 2.544909e-36 Yes
## mean in group 018 2.036586e-133 Yes
## mean in group 019 1.766299e-23 Yes
## mean in group 020 1.260135e-54 Yes
## mean in group 021 5.648475e-134 Yes
## mean in group 022 2.117800e-05 Yes
```

Sí existe sesgo de selección. La tabla muestra que 22 de 23 variables observables presentan diferencias estadísticamente significativas ($p < 0.05$) entre fumadoras y no fumadoras, violando el supuesto de independencia condicional necesario para identificación causal. Las fumadoras son sistemáticamente diferentes: más jóvenes (25.4 vs 27.2 años), menos educadas (11.9 vs 13.1 años), menos casadas (41% vs 18%), con menor uso de cuidado prenatal (10.3 vs 11.2 visitas), y mayor consumo de alcohol (5.2% vs 0.9%) entre otras.

c. Based on your tests in (b), briefly describe the socioeconomic status of smokers compared to non-smokers (i.e. these include variables: tobacco, dimage, dmeduc, dmar, dlivord, nprevist, disllb, dfage, dfeduc, anemia, diabete, phyper, pre4000, preterm, alcohol, drink, foreignb, plural, deadkids, mblack, motherr, mhispan, fblack, fotherr, fhispan).

```
## # A tibble: 2 x 11
##   tobacco age_mother educ_mother married age_father educ_father foreign_born
##   <dbl>    <dbl>    <dbl>    <dbl>    <dbl>    <dbl>    <dbl>
## 1      0      27.2      13.1    0.180      29.5      13.3    0.0503
## 2      1      25.4      11.9    0.414      28.4      12.0    0.0169
## # i 4 more variables: mother_black <dbl>, mother_hispanic <dbl>,
## #   father_black <dbl>, father_hispanic <dbl>
```

Las madres fumadoras presentan un estatus socioeconómico sistemáticamente más vulnerable en comparación con las no fumadoras. En términos de capital humano, las fumadoras tienen, en promedio, un año menos

de educación (11.87 vs 13.12) y son más jóvenes (25.37 vs 27.23 años). Estructuralmente, las fumadoras tienen una probabilidad mucho mayor de no estar casadas (41.3% vs 18%). Además, el tabaquismo es más prevalente en madres afroamericanas (13.9% vs 10.9%) y menos frecuente en madres nacidas en el extranjero o de origen hispano. El perfil de la madre fumadora en esta muestra está asociado a indicadores de menor acumulación de recursos, mayor juventud y menor estabilidad social y económica, factores que por sí mismos correlacionan negativamente con la salud neonatal y proxy que estamos usando de peso.

d. Given the available information in the dataset, do you think “selection on unobservables” may pose a problem (HINT: use the residuals() function)?

```
##
## Welch Two Sample t-test
##
## data: u_hat by tobacco
## t = 51.708, df = 38032, p-value < 2.2e-16
## alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
## 95 percent confidence interval:
## 185.9055 200.5546
## sample estimates:
## mean in group 0 mean in group 1
##      36.06895      -157.16112

##
## Call:
## lm(formula = u_hat ~ tobacco, data = smoking)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3273.2  -303.4    12.7   332.0  3157.0
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   36.069      1.585   22.75  <2e-16 ***
## tobacco     -193.230      3.670  -52.66  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 533.4 on 139147 degrees of freedom
## Multiple R-squared:  0.01954, Adjusted R-squared:  0.01953
## F-statistic: 2773 on 1 and 139147 DF, p-value: < 2.2e-16
```

Sí. Aunque controlemos por variables observables, los residuales del peso al nacer difieren significativamente entre fumadoras y no fumadoras, lo que implica que tobacco está correlacionado con factores no observados que afectan el outcome. Esto es evidencia clara de selección en no observables, por lo que la diferencia de medias y el OLS ajustado no pueden interpretarse como efectos causales sin una estrategia adicional de identificación.

2. Now see if the estimated “effect” of smoking is affected by controlling for observable characteristics in an OLS regression. This procedure is known as “regression adjusting” the difference in means. (25 points)

```
model_1 <- lm(dbirwt ~ tobacco, data = smoking)
summary(model_1)
```

a. First, control for a limited set of demographic characteristics such as race and age. What happens to the coefficient on the smoking indicator variable?

```
##
## Call:
## lm(formula = dbirwt ~ tobacco, data = smoking)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3198.6  -306.6    33.4   347.0  3211.0
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 3425.556      1.702  2012.42  <2e-16 ***
## tobacco     -257.572      3.940   -65.38  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 572.6 on 139147 degrees of freedom
## Multiple R-squared:  0.0298, Adjusted R-squared:  0.02979
## F-statistic: 4274 on 1 and 139147 DF, p-value: < 2.2e-16
```

```
model_2a <- lm(dbirwt ~ tobacco + dmage + dfage +
               mblack + motherr + mhispan + fblack + fotherr + fhispan,
               data = smoking)
summary(model_2a)
```

```
##
## Call:
## lm(formula = dbirwt ~ tobacco + dmage + dfage + mblack + motherr +
##      mhispan + fblack + fotherr + fhispan, data = smoking)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3242.2  -301.7    23.8   346.9  3155.6
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 3343.6227      8.3983  398.130  < 2e-16 ***
## tobacco     -244.4923      3.9194  -62.380  < 2e-16 ***
## dmage         3.9379      0.4258   9.249  < 2e-16 ***
## dfage         0.5171      0.3663   1.412    0.158
## mblack     -200.7892     12.8628  -15.610  < 2e-16 ***
## motherr    -103.5235     19.4955   -5.310  1.10e-07 ***
## mhispan     -74.8025     14.1317   -5.293  1.20e-07 ***
## fblack      -87.5856     12.5169   -6.997  2.62e-12 ***
## fotherr    -128.0929     20.2148   -6.337  2.36e-10 ***
## fhispan     -96.9784     13.4629   -7.203  5.90e-13 ***
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 563.1 on 139139 degrees of freedom
## Multiple R-squared:  0.06196,    Adjusted R-squared:  0.06189
## F-statistic: 1021 on 9 and 139139 DF,  p-value: < 2.2e-16
```

Al controlar por edad y raza de los padres, el coeficiente de tobacco se reduce de -257.6 gramos a -244.5 gramos (aprox. 5%), manteniendo alta la significancia estadística ($p < 2e-16$). Esto nos indica que una pequeña fracción de la diferencia bruta en el peso al nacer se debe a la composición demográfica, pero la persistencia de un efecto de gran magnitud sugiere que el tabaco sigue capturando el impacto de otros confusores omitidos (educación, factores de riesgo, etc.) o que posee un efecto biológico independiente. El incremento del R² de 0.030 a 0.062 confirma que estas variables demográficas explican variación adicional, aunque la mayor parte del peso al nacer sigue sin ser explicada por este modelo sencillo.

```
model_2b <- lm(dbirwt ~ tobacco + dmage + dfage +
               mblack + motherr + mhispan + fblack + fotherr + fhispan +
               dmeduc + dfeduc + dmar + nprevist +
               alcohol + drink,
               data = smoking)
summary(model_2b)
```

b. Now include other controls for other characteristics such as education, prenatal care utilization, and other behavioral risk factors like alcohol consumption. What happens to the “effect” of smoking? What does the p-values indicate with respect to the hypothesis that the coefficients on all of the covariates you just added are zero.

```
##
## Call:
## lm(formula = dbirwt ~ tobacco + dmage + dfage + mblack + motherr +
##      mhispan + fblack + fotherr + fhispan + dmeduc + dfeduc +
##      dmar + nprevist + alcohol + drink, data = smoking)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3190.3  -304.2    21.3   344.6  3109.6
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3151.8465    12.6759  248.649 < 2e-16 ***
## tobacco      -216.6494     4.0480  -53.520 < 2e-16 ***
## dmage         1.8219     0.4458   4.087 4.37e-05 ***
## dfage         0.2730     0.3630   0.752 0.452003
## mblack      -159.5839    12.7394  -12.527 < 2e-16 ***
## motherr      -88.7999    19.2714   -4.608 4.07e-06 ***
## mhispan      -54.0078    13.9741   -3.865 0.000111 ***
## fblack       -45.9601    12.4764   -3.684 0.000230 ***
## fotherr     -110.4705    19.9797   -5.529 3.22e-08 ***
## fhispan      -66.2474    13.3718   -4.954 7.27e-07 ***
## dmeduc        -2.9551     0.9442   -3.130 0.001750 **
## dfeduc         1.7030     0.8716   1.954 0.050726 .
```

```
## dmar          -48.5172      4.5435 -10.678 < 2e-16 ***
## nprevist      24.2390      0.4402  55.063 < 2e-16 ***
## alcohol      -21.2691     14.4324  -1.474 0.140564
## drink         -8.2979      2.8059  -2.957 0.003104 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 556.4 on 139133 degrees of freedom
## Multiple R-squared:  0.0843, Adjusted R-squared:  0.0842
## F-statistic: 853.9 on 15 and 139133 DF,  p-value: < 2.2e-16
```

```
linearHypothesis(model_2b,
                  c("dmeduc = 0", "dfeduc = 0", "dmar = 0",
                    "nprevist = 0", "alcohol = 0", "drink = 0"))
```

```
## Linear hypothesis test
##
## Hypothesis:
## dmeduc = 0
## dfeduc = 0
## dmar = 0
## nprevist = 0
## alcohol = 0
## drink = 0
##
## Model 1: restricted model
## Model 2: dbirwt ~ tobacco + dmage + dfage + mblack + motherr + mhispan +
##          fblack + fotherr + fhispan + dmeduc + dfeduc + dmar + nprevist +
##          alcohol + drink
##
##   Res.Df      RSS Df Sum of Sq    F    Pr(>F)
## 1 139139 4.4118e+10
## 2 139133 4.3067e+10   6 1050713664 565.74 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

c. Finally, include controls for other medical risk factors such as the mother's hypertension. What happens to the effect of smoking? Al incorporar controles adicionales de educación, estado civil, uso de cuidado prenatal y conductas de riesgo, el coeficiente de tobacco se reduce de -244.5 gramos a -216.6 gramos, lo que indica que una parte relevante del efecto estimado previamente estaba capturando diferencias socioeconómicas y de comportamiento entre fumadoras y no fumadoras. Aun así, el efecto del tabaco sigue siendo grande y altamente significativo, lo que sugiere que fumar durante el embarazo está fuertemente asociado con menores pesos al nacer, incluso después de un ajuste sustancial por observables. El test F conjunto rechaza la hipótesis nula de que los coeficientes de las nuevas covariables sean cero, confirmando que educación, cuidado prenatal y consumo de alcohol explican de manera conjunta una fracción importante de la variación en el peso al nacer,

d.BRIEFLY explain why adding these controls may be inappropriate. Aunque el control por educación, estado civil, uso de cuidado prenatal y conductas de riesgo reduce el coeficiente estimado de tobacco, la inclusión de estas variables puede ser inapropiada porque variables como el número de visitas prenatales y el consumo de alcohol pueden ser “canales” del efecto del tabaquismo. Si la madre fuma durante el embarazo puede afectar el comportamiento de cuidado de la madre o su estado de salud, y controlar por

estas variables elimina parte del mecanismo a través del cual el tabaco impacta el peso al nacer, llevando a una subestimación del efecto.

Además, estos controles pueden ser endógenos, ya que están influenciados por factores no observados como acceso, preferencias por la salud, estrés o desventajas socioeconómicas no observadas en las variables que tenemos y también afectan el peso al nacer. Al condicionar en variables determinadas simultáneamente o posteriormente al tratamiento, el modelo puede introducir sesgos adicionales en lugar de corregirlos.

Part 5 (30 points)

These questions ask you to analyze a data set with information that was collected as part of the randomized evaluation of the US Federal Job Corps Program. Before getting started, read the description of the program in Schochet, Peter, John Burghardt and Sheena McConnell. 2008. “Does Job Corps Work? Impact Findings from the National Job Corps Study.” American Economic Review, 98(5). The data set is called `jobcorps.dta` and is located in Canvas

```
df_bal <- subset(jobs, !is.na(male) & !is.na(treatmnt))  
  
t.test(male ~ treatmnt, data = df_bal)
```

a. Assess the success of randomization. Using the `t.test` command, test whether the difference in the fraction male was different in the experimental (`treatmnt==1`) and control group (`treatmnt==0`). What does this suggest?

```
##  
## Welch Two Sample t-test  
##  
## data: male by treatmnt  
## t = 9.7337, df = 11944, p-value < 2.2e-16  
## alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0  
## 95 percent confidence interval:  
## 0.06603005 0.09933011  
## sample estimates:  
## mean in group 0 mean in group 1  
## 0.6519337 0.5692536  
  
with(df_bal, tapply(male, treatmnt, mean))  
  
## 0 1  
## 0.6519337 0.5692536
```

La aleatorización para la variable género fue desbalanceada porque existe una diferencia de 8.3 puntos porcentuales entre grupos y esta es estadísticamente significativa ($p < 0.01$). Esto sugiere un sesgo de selección o que los hombres en el grupo de tratamiento tuvieron una mayor tasa de abandono (attrition) en el estudio.

```

vars_baseline <- c(
  "white", "black", "hispanic", "eng_sec_language", "male",
  "havekids_at_bline",
  "educlevel_at_bline", "hsgrad_at_bline", "ged_at_bline",
  "everwork_at_bline", "wrk_lyr_bline", "mos_wrk_lyr_bline",
  "earn_lyr_bline", "wage_bline",
  "anywlfr_bline", "alcohol_bline", "arrest_bline", "jail_bline"
)

balance_test <- function(var, data) {
  formula <- as.formula(paste(var, "~ treatmnt"))
  test <- t.test(formula, data = data)

  data.frame(
    variable = var,
    mean_control = test$estimate[1],
    mean_treatment = test$estimate[2],
    diff = test$estimate[2] - test$estimate[1],
    p_value = test$p.value,
    significant = ifelse(test$p.value < 0.05, "***", "")
  )
}

balance_results <- do.call(rbind, lapply(vars_baseline, balance_test, data = jobs))

balance_results <- balance_results[order(balance_results$p_value), ]
rownames(balance_results) <- NULL

print(balance_results, digits = 4)

```

b. Conduct similar tests of the randomization using other variables [Hint: be careful about the observable characteristics that you analyze]

##	variable	mean_control	mean_treatment	diff	p_value
## 1	male	6.519e-01	5.693e-01	-0.082680	2.621e-22
## 2	havekids_at_bline	1.771e-01	2.007e-01	0.023568	5.943e-04
## 3	ged_at_bline	5.345e-02	4.558e-02	-0.007862	4.043e-02
## 4	jail_bline	7.581e-02	6.690e-02	-0.008910	5.542e-02
## 5	arrest_bline	2.698e-01	2.568e-01	-0.013045	9.196e-02
## 6	hsgrad_at_bline	1.766e-01	1.859e-01	0.009323	1.680e-01
## 7	everwork_at_bline	7.887e-01	7.985e-01	0.009777	1.695e-01
## 8	wage_bline	5.092e+00	5.055e+00	-0.037201	2.533e-01
## 9	anywlfr_bline	5.792e-01	5.896e-01	0.010401	2.557e-01
## 10	educlevel_at_bline	1.006e+01	1.009e+01	0.028813	2.806e-01
## 11	alcohol_bline	5.781e-01	5.873e-01	0.009182	2.889e-01
## 12	hispanic	1.829e-01	1.758e-01	-0.007099	2.925e-01
## 13	wrk_lyr_bline	6.372e-01	6.439e-01	0.006726	4.246e-01
## 14	earn_lyr_bline	2.908e+03	2.976e+03	68.310995	4.905e-01
## 15	white	2.621e-01	2.664e-01	0.004325	5.761e-01
## 16	eng_sec_language	1.446e-01	1.414e-01	-0.003238	5.989e-01
## 17	black	4.820e-01	4.850e-01	0.002916	7.395e-01
## 18	mos_wrk_lyr_bline	3.681e+00	3.703e+00	0.022269	7.659e-01
##	significant				

```
## 1      ***
## 2      ***
## 3      ***
## 4
## 5
## 6
## 7
## 8
## 9
## 10
## 11
## 12
## 13
## 14
## 15
## 16
## 17
## 18
```

```
X <- c("male", "white", "black", "hispanic", "eng_sec_language",
      "havekids_at_bline", "educlevel_at_bline", "hsgrad_at_bline",
      "ged_at_bline",
      "mos_wrk_lyr_bline", "earn_lyr_bline", "wage_bline",
      "anywlfr_bline", "alcohol_bline", "arrest_bline", "jail_bline")

df <- jobs[, c("treatmnt", "dsgn_wgt", X)]
df <- df[complete.cases(df), ]

fml <- as.formula(paste("treatmnt ~", paste(X, collapse = " + ")))
lpm_weighted <- lm(fml, data = df, weights = dsgn_wgt)

summary(lpm_weighted)
```

c. Another way to test the randomization is by seeing how closely the observable characteristics can predict whether someone is in the experimental group or the control group. One way to implement this test is by running the following regression:

```
##
## Call:
## lm(formula = fml, data = df, weights = dsgn_wgt)
##
## Weighted Residuals:
##      Min       1Q   Median       3Q      Max
## -2.493 -1.694  1.353  1.534  1.818
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    5.920e-01  6.692e-02   8.847  <2e-16 ***
## male          -2.206e-02  1.352e-02  -1.631   0.1029
## white         -2.886e-02  2.874e-02  -1.004   0.3153
## black         -3.897e-02  2.797e-02  -1.393   0.1636
```

```
## hispanic          -3.845e-02  2.895e-02  -1.328  0.1841
## eng_sec_language  -1.328e-02  2.390e-02  -0.556  0.5786
## havekids_at_bline -1.325e-02  1.695e-02  -0.781  0.4347
## educlevel_at_bline -6.101e-03  5.765e-03  -1.058  0.2900
## hsgrad_at_bline   -7.893e-03  2.033e-02  -0.388  0.6979
## ged_at_bline      -5.546e-02  2.709e-02  -2.047  0.0407 *
## mos_wrk_lyr_bline -5.257e-04  2.418e-03  -0.217  0.8279
## earn_lyr_bline     3.470e-07  2.003e-06   0.173  0.8625
## wage_bline         2.053e-03  4.908e-03   0.418  0.6758
## anywlfr_bline      -2.827e-03  1.317e-02  -0.215  0.8300
## alcohol_bline      1.558e-02  1.356e-02   1.149  0.2507
## arrest_bline       -6.589e-03  1.733e-02  -0.380  0.7038
## jail_bline         2.111e-02  2.825e-02   0.747  0.4550
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.628 on 6377 degrees of freedom
## Multiple R-squared:  0.002231, Adjusted R-squared:  -0.0002722
## F-statistic: 0.8913 on 16 and 6377 DF, p-value: 0.5794
```

```
linearHypothesis(lpm_weighted, X)
```

```
## Linear hypothesis test
##
## Hypothesis:
## male = 0
## white = 0
## black = 0
## hispanic = 0
## eng_sec_language = 0
## havekids_at_bline = 0
## educlevel_at_bline = 0
## hsgrad_at_bline = 0
## ged_at_bline = 0
## mos_wrk_lyr_bline = 0
## earn_lyr_bline = 0
## wage_bline = 0
## anywlfr_bline = 0
## alcohol_bline = 0
## arrest_bline = 0
## jail_bline = 0
##
## Model 1: restricted model
## Model 2: treatmnt ~ male + white + black + hispanic + eng_sec_language +
##      havekids_at_bline + educlevel_at_bline + hsgrad_at_bline +
##      ged_at_bline + mos_wrk_lyr_bline + earn_lyr_bline + wage_bline +
##      anywlfr_bline + alcohol_bline + arrest_bline + jail_bline
##
##      Res.Df    RSS Df Sum of Sq      F Pr(>F)
## 1      6393 16929
## 2      6377 16891 16      37.772 0.8913 0.5794
```

```
cat("\nObservaciones usadas:", nrow(df), "de", nrow(jobs), "\n")
```

```
##
## Observaciones usadas: 6394 de 13509
```

$$\text{treatmnt}_i = \alpha + \mathbf{X}_i' \boldsymbol{\beta} + u_i$$

donde $\mathbf{X}_i$ incluye características demográficas (género, raza/etnicidad, idioma), composición familiar, educación baseline, experiencia laboral previa, ingresos y salarios del año anterior, así como antecedentes de asistencia social, consumo de alcohol y problemas legales. La regresión se estima por mínimos cuadrados ponderados usando los pesos de diseño muestral (`dsgn_wgt`). Bajo aleatorización exitosa, $H_0 : \boldsymbol{\beta} = \mathbf{0}$.

d. What is your overall impression from these results? Was the randomization successful? [limit your discussion to about 3 sentences] Los resultados indican que la aleatorización fue exitosa, ya que el modelo tiene un poder predictivo casi nulo ($R^2=0.0022$) y la prueba F conjunta no es estadísticamente significativa ($p=0.5794$), lo que impide rechazar la hipótesis nula de que las covariables no predicen la asignación al tratamiento. A diferencia de los resultados no ponderados, al aplicar los pesos de diseño y corregir la muestra, las características observables están globalmente balanceadas entre los grupos. Esto sugiere que las diferencias individuales previas son producto del azar y que el grupo de tratamiento y control son comparables para la estimación del impacto causal.

```
X <- c("male", "white", "black", "hispanic", "eng_sec_language",
      "havekids_at_bline", "educlevel_at_bline", "hsgrad_at_bline",
      "ged_at_bline", "mos_wrk_lyr_bline", "earn_lyr_bline", "wage_bline",
      "anywlfr_bline", "alcohol_bline", "arrest_bline", "jail_bline")

fml_attrit <- as.formula(paste("attrit ~", paste(X, collapse = " + ")))
lpm_attrit <- lm(fml_attrit, data = jobs)

summary(lpm_attrit)
```

e. A serious problem that often arises during randomized evaluation is sample attrition. Compare the characteristics of individuals who drop out of the sample and those that complete the 48 month follow-up (attrit=0). Does it appear as though there is systematic attrition, or does it appear as though attrition is not systematically related to observables?

```
##
## Call:
## lm(formula = fml_attrit, data = jobs)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.33833 -0.20174 -0.15254 -0.09554  0.94685
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.796e-01  4.947e-02   3.630 0.000285 ***
## male        7.760e-02  1.019e-02   7.613 3.07e-14 ***
```

```
## white          -4.024e-02  2.145e-02  -1.876  0.060648 .
## black          -3.923e-02  2.085e-02  -1.882  0.059883 .
## hispanic       -1.870e-03  2.162e-02  -0.086  0.931093
## eng_sec_language -3.002e-02  1.771e-02  -1.695  0.090191 .
## havekids_at_bline -1.578e-05  1.246e-02  -0.001  0.998989
## educlevel_at_bline -2.927e-03  4.262e-03  -0.687  0.492226
## hsgrad_at_bline  7.301e-04  1.509e-02   0.048  0.961424
## ged_at_bline    -5.706e-03  2.042e-02  -0.279  0.779941
## mos_wrk_lyr_bline -3.855e-03  1.798e-03  -2.144  0.032057 *
## earn_lyr_bline   2.001e-06  1.483e-06   1.349  0.177482
## wage_bline       9.036e-03  3.626e-03   2.492  0.012726 *
## anywlfr_bline    -3.662e-02  9.813e-03  -3.732  0.000192 ***
## alcohol_bline    -1.049e-02  1.009e-02  -1.040  0.298462
## arrest_bline     1.536e-02  1.295e-02   1.187  0.235373
## jail_bline       -2.515e-02  2.094e-02  -1.201  0.229903
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3725 on 6377 degrees of freedom
## (7115 observations deleted due to missingness)
## Multiple R-squared:  0.01918,    Adjusted R-squared:  0.01672
## F-statistic: 7.793 on 16 and 6377 DF,  p-value: < 2.2e-16
```

```
linearHypothesis(lpm_attrit, X)
```

```
## Linear hypothesis test
##
## Hypothesis:
## male = 0
## white = 0
## black = 0
## hispanic = 0
## eng_sec_language = 0
## havekids_at_bline = 0
## educlevel_at_bline = 0
## hsgrad_at_bline = 0
## ged_at_bline = 0
## mos_wrk_lyr_bline = 0
## earn_lyr_bline = 0
## wage_bline = 0
## anywlfr_bline = 0
## alcohol_bline = 0
## arrest_bline = 0
## jail_bline = 0
##
## Model 1: restricted model
## Model 2: attrit ~ male + white + black + hispanic + eng_sec_language +
##      havekids_at_bline + educlevel_at_bline + hsgrad_at_bline +
##      ged_at_bline + mos_wrk_lyr_bline + earn_lyr_bline + wage_bline +
##      anywlfr_bline + alcohol_bline + arrest_bline + jail_bline
##
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1    6393 902.21
## 2    6377 884.91 16    17.301 7.7926 < 2.2e-16 ***
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Si existe evidencia de abandono (attrition) sistemático. Las características baseline predicen de manera conjunta y significativa la probabilidad de abandono ($F=7.79$, $p<0.001$), y varias covariables individuales (male, anywfr_bline, wage_bline y mos_wrk_lyr_bline) están estadísticamente asociadas con el abandono. Por lo tanto, attrition no es aleatoria con respecto a observables.

f. Briefly (1-2 sentences) explain why attrition complicates estimation of experimental impacts, even with successful randomization. El abandono (attrition) complica la estimación de impactos en RCT's porque induce selección no aleatoria posterior a la asignación, rompiendo la equivalencia entre los grupos de tratamiento y control incluso si la aleatorización del principio fue exitosa. Cuando el abandono (attrition) está correlacionado con características observables o no observables que también afectan los resultados, el estimador de diferencia de medias deja de identificar el efecto causal del tratamiento.

g. Propose a strategy for testing whether attrition is likely to pose a problem for this randomized evaluation. Una estrategia podría consistir en modelar el abandono (attrition) como función de características pre-tratamiento y de la asignación al tratamiento, estimando

$$attrition_i = \alpha + \delta treatment_i + X_i'\gamma + u_i$$

y evaluando si (i) $\delta = 0$ (abandono diferencial por tratamiento) y/o (ii) X_i predice conjuntamente el abandono.

```
X <- c("male", "white", "black", "hispanic", "eng_sec_language",
      "havekids_at_bline", "educlevel_at_bline", "hsgrad_at_bline",
      "ged_at_bline", "mos_wrk_lyr_bline", "earn_lyr_bline", "wage_bline",
      "anywfr_bline", "alcohol_bline", "arrest_bline", "jail_bline")

df <- jobs[, c("attrit", "treatmnt", "dsgn_wgt", X)]
df <- df[complete.cases(df), ]
df$attrit <- as.integer(df$attrit)

fml_attrit2 <- as.formula(paste("attrit ~ treatmnt +", paste(X, collapse = " + ")))
m_attrit <- lm(fml_attrit2, data = df, weights = dsgn_wgt)

summary(m_attrit)
```

h. Implement your proposed test using the job corps data. Does it appear that attrition is a problem?

```
##
## Call:
## lm(formula = fml_attrit2, data = df, weights = dsgn_wgt)
##
## Weighted Residuals:
##      Min       1Q   Median       3Q      Max
## -1.2363 -0.6503 -0.4878 -0.2701  4.1506
##
```

```
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   1.765e-01  4.997e-02   3.532 0.000415 ***
## treatmnt      -9.025e-03  9.293e-03  -0.971 0.331504
## male          8.493e-02  1.004e-02   8.461 < 2e-16 ***
## white        -3.648e-02  2.133e-02  -1.710 0.087258 .
## black        -3.031e-02  2.076e-02  -1.460 0.144409
## hispanic      7.230e-03  2.148e-02   0.337 0.736489
## eng_sec_language -3.121e-02  1.774e-02  -1.760 0.078533 .
## havekids_at_bline 4.952e-03  1.258e-02   0.394 0.693954
## educlevel_at_bline -4.164e-03  4.279e-03  -0.973 0.330481
## hsgrad_at_bline  9.010e-03  1.509e-02   0.597 0.550454
## ged_at_bline   -3.090e-04  2.011e-02  -0.015 0.987744
## mos_wrk_lyr_bline -3.465e-03  1.795e-03  -1.931 0.053536 .
## earn_lyr_bline  1.983e-06  1.486e-06   1.334 0.182131
## wage_bline     9.527e-03  3.643e-03   2.615 0.008936 **
## anywlfr_bline  -3.838e-02  9.771e-03  -3.927 8.68e-05 ***
## alcohol_bline  -7.018e-03  1.006e-02  -0.697 0.485599
## arrest_bline   1.719e-02  1.286e-02   1.337 0.181419
## jail_bline     -2.742e-02  2.097e-02  -1.308 0.191027
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.208 on 6376 degrees of freedom
## Multiple R-squared:  0.02177,    Adjusted R-squared:  0.01916
## F-statistic: 8.345 on 17 and 6376 DF,  p-value: < 2.2e-16
```

```
linearHypothesis(m_attrit, "treatmnt = 0")
```

```
## Linear hypothesis test
##
## Hypothesis:
## treatmnt = 0
##
## Model 1: restricted model
## Model 2: attrit ~ treatmnt + male + white + black + hispanic + eng_sec_language +
##      havekids_at_bline + educlevel_at_bline + hsgrad_at_bline +
##      ged_at_bline + mos_wrk_lyr_bline + earn_lyr_bline + wage_bline +
##      anywlfr_bline + alcohol_bline + arrest_bline + jail_bline
##
##      Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      6377 9302.8
## 2      6376 9301.4  1    1.3759 0.9432 0.3315
```

```
linearHypothesis(m_attrit, X)
```

```
## Linear hypothesis test
##
## Hypothesis:
## male = 0
## white = 0
## black = 0
## hispanic = 0
```



```
## eng_sec_language = 0
## havekids_at_bline = 0
## educlevel_at_bline = 0
## hsgrad_at_bline = 0
## ged_at_bline = 0
## mos_wrk_lyr_bline = 0
## earn_lyr_bline = 0
## wage_bline = 0
## anywlfr_bline = 0
## alcohol_bline = 0
## arrest_bline = 0
## jail_bline = 0
##
## Model 1: restricted model
## Model 2: attrit ~ treatmnt + male + white + black + hispanic + eng_sec_language +
##      havekids_at_bline + educlevel_at_bline + hsgrad_at_bline +
##      ged_at_bline + mos_wrk_lyr_bline + earn_lyr_bline + wage_bline +
##      anywlfr_bline + alcohol_bline + arrest_bline + jail_bline
##
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1    6392 9506.7
## 2    6376 9301.4 16    205.28 8.7949 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
cat("\nObservaciones usadas:", nrow(df), "de", nrow(jobs), "\n")
```

```
##
## Observaciones usadas: 6394 de 13509
```

```
jobs48 <- subset(jobs, attrit == 0)

tt_earnq1 <- t.test(earnq1 ~ treatmnt, data = jobs48)

tt_earnq1
```

i. For the rest of the questions, only use individuals who complete the 48 month follow-up. Use the subset() function to retain only the data points for which attrit==1. Estimate the experimental impact on earnings in the first quarter after random assignment and test whether the estimated impacts are statistically distinguishable from zero.

```
##
## Welch Two Sample t-test
##
## data:  earnq1 by treatmnt
## t = 10.241, df = 7631.7, p-value < 2.2e-16
## alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
## 95 percent confidence interval:
##  17.62906 25.97520
## sample estimates:
```

```
## mean in group 0 mean in group 1
##      64.49959      42.69746

impact_hat <- unname(diff(tt_earnq1$estimate))
pval <- tt_earnq1$p.value
ci <- tt_earnq1$conf.int

cat("Impacto estimado (earnq1):", impact_hat, "\n")
```

```
## Impacto estimado (earnq1): -21.80213
```

```
cat("p-value:", pval, "\n")
```

```
## p-value: 1.860843e-24
```

```
cat("IC 95%:", ci[1], ",", ci[2], "\n")
```

```
## IC 95%: 17.62906 , 25.9752
```

j. Given the structure of the Job Corps program, provide an explanation for this result. En el primer trimestre tras la asignación aleatoria, los individuos del grupo de tratamiento suelen estar participando en capacitación intensiva (Job Corps), lo que reduce en su su tiempo disponible para trabajar en el mercado laboral. Por el contrario, los individuos del grupo control no reciben el programa y, por lo tanto, entran o permanecen en empleo inmediatamente, generando mayores ingresos en el corto plazo. Dado que `earnq1` mide ingresos laborales muy tempranos y no el efecto de largo plazo del capital acumulado, el impacto negativo puede reflejar un efecto de sustitución temporal entre formación y trabajo, y no necesariamente un fracaso del programa.

```
jobs48 <- subset(jobs, attrit == 0)

qs <- 2:16

effects <- do.call(rbind, lapply(qs, function(q){
  y <- paste0("earnq", q)
  tt <- t.test(jobs48[[y]] ~ jobs48$treatmnt)

  est_tc <- unname(tt$estimate["mean in group 1"] - tt$estimate["mean in group 0"])
  ci_ct <- tt$conf.int
  ci_tc <- c(-ci_ct[2], -ci_ct[1])


  data.frame(
    quarter = q,
    effect = est_tc,
    ci_low = ci_tc[1],
    ci_high = ci_tc[2],
    p_value = tt$p.value
  )
}))

effects
```

k. Now estimate the experimental impact on earnings in quarters 2-16 after random assignment. What does these result suggest about the time-profile of the effect of being in the Job Corps program? [It may be useful to plot the estimated effect as a function of time]

	quarter	effect	ci_low	ci_high	p_value
## 1	2	-29.639952	-34.73577744	-24.544126	7.020417e-30
## 2	3	-22.657561	-28.11051822	-17.204604	4.342636e-16
## 3	4	-15.613343	-21.07690710	-10.149779	2.186194e-08
## 4	5	-10.466243	-16.37370641	-4.558780	5.172495e-04
## 5	6	-4.819987	-11.47039546	1.830421	1.554374e-01
## 6	7	2.131873	-4.85741325	9.121159	5.499171e-01
## 7	8	4.354385	-2.78898614	11.497757	2.321599e-01
## 8	9	6.345817	-0.86958763	13.561221	8.474517e-02
## 9	10	7.310715	0.07072228	14.550708	4.780415e-02
## 10	11	11.795577	4.44447020	19.146683	1.664026e-03
## 11	12	13.421586	5.57837328	21.264798	7.985177e-04
## 12	13	13.816526	5.68582127	21.947231	8.686735e-04
## 13	14	11.227564	2.93487878	19.520250	7.968663e-03
## 14	15	11.045576	2.87377230	19.217380	8.073006e-03
## 15	16	13.144888	4.98019623	21.309580	1.605159e-03

```
ggplot(effects, aes(x = quarter, y = effect)) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray40") +
  geom_ribbon(aes(ymin = ci_low, ymax = ci_high), alpha = 0.2) +
  geom_line(linewidth = 0.9) +
  geom_point(size = 2) +
  labs(
    x = "Trimestre después de la asignación (q)",
    y = "Impacto estimado en earnings: E[earnq] (tratamiento - control)",
    title = "Perfil temporal del impacto de Job Corps sobre earnings (q2-q16)",
    subtitle = "Muestra: completan follow-up 48 meses (attrit==0); IC 95% sombreado"
  ) +
  theme_minimal()
```



Si existe un efecto de inversión en capital humano caracterizado por un sesgo de selección negativo inicial debido al costo de oportunidad de la capacitación, seguido de una convergencia y posterior transición hacia impactos positivos y estadísticamente significativos a partir del décimo trimestre, lo que confirma retornos positivos al programa en el mediano plazo.

```
X <- c("male", "white", "black", "hispanic", "eng_sec_language",
      "havekids_at_bline", "educlevel_at_bline", "hsgrad_at_bline",
      "ged_at_bline", "mos_wrk_lyr_bline", "earn_lyr_bline", "wage_bline",
      "anywlfr_bline", "alcohol_bline", "arrest_bline", "jail_bline")

jobs$miss_earnq1 <- as.integer(is.na(jobs$earnq1))

df <- jobs[, c("miss_earnq1", "treatmnt", "dsgn_wgt", X)]
df <- df[complete.cases(df[, c("miss_earnq1", "treatmnt", "dsgn_wgt", X)]), ]

fml_miss <- as.formula(paste("miss_earnq1 ~ treatmnt +", paste(X, collapse = " + ")))
m_miss <- lm(fml_miss, data = df, weights = dsgn_wgt)

summary(m_miss)
```

1. Another serious problem in randomized evaluations is that key variables are, for some reason, missing. Using a similar strategy to that proposed in g, test whether missing data is likely to be a serious problem in the Jops Cops evaluation.

```
##
## Call:
## lm(formula = fml_miss, data = df, weights = dsgn_wgt)
##
## Weighted Residuals:
##      Min       1Q   Median       3Q      Max
## -1.4717 -0.7630 -0.5650 -0.2988  4.0514
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    2.037e-01  5.349e-02   3.808 0.000142 ***
## treatmnt      -1.526e-02  9.948e-03  -1.534 0.124972
## male          9.380e-02  1.075e-02   8.729 < 2e-16 ***
## white        -1.803e-02  2.283e-02  -0.789 0.429901
## black        -2.329e-02  2.223e-02  -1.048 0.294663
## hispanic       7.487e-03  2.300e-02   0.326 0.744773
## eng_sec_language -1.877e-02  1.899e-02  -0.988 0.323036
## havekids_at_bline 1.483e-02  1.347e-02   1.101 0.270818
## educlevel_at_bline -6.045e-03  4.580e-03  -1.320 0.186932
## hsgrad_at_bline  -2.032e-03  1.615e-02  -0.126 0.899916
## ged_at_bline    1.031e-02  2.153e-02   0.479 0.632128
## mos_wrk_lyr_bline -3.646e-03  1.921e-03  -1.898 0.057735 .
## earn_lyr_bline   1.388e-06  1.591e-06   0.873 0.382951
## wage_bline      1.216e-02  3.899e-03   3.119 0.001820 **
## anywlfr_bline   -3.913e-02  1.046e-02  -3.741 0.000185 ***
## alcohol_bline   -3.483e-04  1.077e-02  -0.032 0.974210
## arrest_bline    1.537e-02  1.377e-02   1.117 0.264172
## jail_bline      -2.793e-02  2.245e-02  -1.244 0.213430
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.293 on 6376 degrees of freedom
## Multiple R-squared:  0.02343,    Adjusted R-squared:  0.02082
## F-statistic: 8.998 on 17 and 6376 DF,  p-value: < 2.2e-16
```

```
linearHypothesis(m_miss, "treatmnt = 0")
```

```
## Linear hypothesis test
##
## Hypothesis:
## treatmnt = 0
##
## Model 1: restricted model
## Model 2: miss_earnq1 ~ treatmnt + male + white + black + hispanic + eng_sec_language +
##      havekids_at_bline + educlevel_at_bline + hsgrad_at_bline +
##      ged_at_bline + mos_wrk_lyr_bline + earn_lyr_bline + wage_bline +
##      anywlfr_bline + alcohol_bline + arrest_bline + jail_bline
##
##      Res.Df    RSS Df Sum of Sq      F Pr(>F)
## 1      6377 10662
## 2      6376 10658   1      3.9358 2.3545 0.125
```

```
linearHypothesis(m_miss, X)
```

```
## Linear hypothesis test
##
## Hypothesis:
## male = 0
## white = 0
## black = 0
## hispanic = 0
## eng_sec_language = 0
## havekids_at_bline = 0
## educlevel_at_bline = 0
## hsgrad_at_bline = 0
## ged_at_bline = 0
## mos_wrk_lyr_bline = 0
## earn_lyr_bline = 0
## wage_bline = 0
## anywlfr_bline = 0
## alcohol_bline = 0
## arrest_bline = 0
## jail_bline = 0
##
## Model 1: restricted model
## Model 2: miss_earnq1 ~ treatmnt + male + white + black + hispanic + eng_sec_language +
##      havekids_at_bline + educlevel_at_bline + hsgrad_at_bline +
##      ged_at_bline + mos_wrk_lyr_bline + earn_lyr_bline + wage_bline +
##      anywlfr_bline + alcohol_bline + arrest_bline + jail_bline
##
##      Res.Df    RSS Df Sum of Sq      F    Pr(>F)
## 1      6392 10910
## 2      6376 10658 16      251.31 9.3962 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
cat("\nN usado:", nrow(df), "de", nrow(jobs), "\n")
```

```
##
## N usado: 6394 de 13509
```

```
cat("Tasa de missing en earnq1:", mean(jobs$miss_earnq1, na.rm = TRUE), "\n")
```

```
## Tasa de missing en earnq1: 0.2178548
```

La falta de datos en la variable clave constituye un problema serio de selección no aleatoria, ya que, aunque no existe evidencia de un patrón diferencial por asignación al tratamiento ($p=0.125$), las características observables del baseline predicen de manera conjunta y altamente significativa la probabilidad de tener datos faltantes. Específicamente, variables como el género masculino, el salario previo y la asistencia social están fuertemente correlacionadas con la ausencia de información, lo que sugiere que el mecanismo de pérdida de datos no es aleatorio y podría sesgar las estimaciones del impacto experimental. Creemos que se deben generar técnicas de imputación o de IPW para robustecer los resultados.

Declaración de uso de IA (ChatGPT)

Para la elaboración de este Problem Set se utilizó IA generativa (ChatGPT) como apoyo para: (i) verificar derivaciones y resultados, (ii) depurar/organizar código en R, y (iii) mejorar redacción y claridad. Las conversaciones y prompts utilizados se incluyen como evidencia en el Anexo 1.

Anexo 1. Evidencias de conversaciones con ChatGPT

qué significa no selección en no observables en el contexto de regresiones e inferencia causal

En regresiones e inferencia causal, “no selección en no observables” es el supuesto de que la asignación al tratamiento no depende de factores no observados que también afectan el resultado, una vez que ya controlaste por las variables observables incluidas en el modelo.

Dicho de forma directa:

Condicionado a X , el tratamiento D es independiente de los determinantes no observados de Y .

Intuición

Si dos personas (o unidades) son iguales en todo lo que puedes medir y que incluyes como controles, entonces **quién recibe el tratamiento es “como al azar”** respecto a lo que no puedes medir. Bajo ese supuesto, la diferencia promedio en el resultado puede interpretarse como efecto causal.

Forma formal (potenciales resultados)

Se suele expresar como:

$$(Y(0), Y(1)) \perp\!\!\!\perp D \mid X$$

Esto implica que, dado X , el tratamiento no está correlacionado con los potenciales resultados.

Por qué es clave

- Garantiza que **no hay sesgo por variables omitidas** relevantes.
- Permite interpretar el coeficiente de una regresión (o el estimador de matching, IPW, etc.) como **efecto causal**, no solo correlación.

Ejemplo sencillo

Supón que estimas el efecto de **educación** sobre **ingresos** controlando por edad y género.

- El problema aparece si existe una variable no observada, como **habilidad innata** o **motivación**, que:
 1. influye en cuánta educación alguien obtiene, y
 2. también afecta sus ingresos.

En ese caso **hay selección en no observables**, el supuesto se viola y la regresión estará sesgada.

Qué pasa si el supuesto no se cumple

- La estimación por OLS, matching o regresión con controles **no identifica el efecto causal**.
- El sesgo puede ir en cualquier dirección y no desaparece con más controles observables.

Métodos que intentan lidiar con esto

Cuando sospechas selección en no observables, se buscan estrategias que no dependan de este supuesto:

- Variables instrumentales (IV)
- Diferencias en diferencias
- Regresión discontinua
- Control sintético
- Experimentos aleatorios

En resumen: “no selección en no observables” significa que, una vez controlado por lo que observas, **lo no observado no empuja simultáneamente el tratamiento y el resultado**. Es un supuesto fuerte, generalmente no testeable, y por eso es el punto débil central de muchas regresiones “naïve” con pretensión causal.

Pero entonces solo se refiere a la correcta inclusión o no de las variables que afectan a la resultado, no?

Casi, pero no exactamente. La clave es esta distinción:

No se refiere solo a incluir bien las variables que afectan al resultado, sino a incluir (o neutralizar) todas las variables que afectan *simultáneamente* al tratamiento y al resultado.

Dicho de otra forma:

no importa tanto si omites una variable que solo afecta a Y ; el problema serio aparece cuando omites una variable que afecta a D y a Y .

Descomposición clara

1. Variables que afectan solo al resultado (Y)
 - Omitirlas reduce precisión (más varianza).
 - No genera sesgo causal per se.
 - No viola “no selección en no observables”.
2. Variables que afectan solo al tratamiento (D)
 - Omitidas **generan** sesgo al efecto causal.

- Omitirlas tampoco sesga el efecto causal.
- A lo más, afecta eficiencia o interpretación.

3. Variables que afectan a D y a Y (confusores)

- Si son **no observadas**, hay selección en no observables.
- Aquí es donde se rompe la identificación causal.

Forma intuitiva

El supuesto dice:

“Condicionado a los controles X , no queda *ninguna* fuerza no observada que empuje tanto la probabilidad de tratamiento como el resultado”.

No exige que controles **todo lo que explica Y** , sino **todo lo que explica la correlación espuria entre D y Y** .

Ejemplo rápido

Educación (D) $\rightarrow$ Ingresos (Y)

- Habilidad innata: afecta educación y salarios $\rightarrow$ confusor no observado $\rightarrow$ problema.
- Choque de salud inesperado: afecta salarios pero no educación $\rightarrow$ no es un problema de selección.
- Distancia a la universidad: afecta educación pero no salarios directamente $\rightarrow$ no es selección en no observables (puede ser instrumento).

Una forma compacta de decirlo en clase o en un paper

El supuesto de no selección en no observables requiere que, una vez controlado por X , no existan confusores no observados que determinen simultáneamente la asignación al tratamiento y el resultado.

Si quieres, puedo ayudarte a traducir esto a una frase “de manual” para notas de clase, o a un diagrama causal tipo DAG para explicarlo visualmente.

📄 👍 🗨️ ⬆️ ↺ ...

Sí, me refiero a la inclusión o no de variables omitidas

Entonces sí, pero con una precisión importante.

“**No selección en no observables**” equivale a suponer que **no hay variables omitidas no observadas que sean confusores**, es decir, que afecten al tratamiento y al resultado al mismo tiempo.

No es simplemente “incluir bien todas las variables relevantes”, sino **no omitir variables no observadas que generen correlación espuria entre D y Y** .

En términos de sesgo por variable omitida:

- Si omites una variable U tal que $U \rightarrow Y$ pero $U \nrightarrow D$:
no hay problema de selección; pierdes precisión, no identificación.
- Si omites una variable U tal que $U \rightarrow D$ pero $U \nrightarrow Y$:
tampoco hay problema de selección.
- Si omites una variable U tal que $U \rightarrow D$ y $U \rightarrow Y$:
hay selección en no observables y el coeficiente de D está sesgado.

Por eso, dicho de manera limpia:

El supuesto de no selección en no observables es el supuesto de que **no existen variables omitidas no observadas que sean confusores**.

Y por eso es un supuesto **no testeable** con los datos, y el punto débil central de regresiones “con controles”.

Si quieres una frase aún más corta para usarla como regla mental o en una diapositiva:

No selección en no observables = no confusores no observados.

Eso es exactamente lo que estás señalando.

📄 👍 🗨️ ⬆️ ↺ ...

Entonces el uso de un método como MCO que, digamos, cumple la no selección de no observables, no garantiza la reducción de la dimensionalidad no? Porque incluso si se cumple, si la relación subyacente de las variables es no lineal, pues los estimadores serán sesgados?

Exacto. Estás mezclando **dos planos distintos**, y es importante no confundirlos:

1. Identificación causal (selección)
2. Correcta especificación funcional (forma del modelo)

Que MCO cumpla **no selección en no observables** no implica que el modelo esté bien especificado ni que la

“dimensionalidad” esté resuelta.

1. No selección ≠ correcta especificación

El supuesto de no selección en no observables dice algo **solo sobre correlación entre D y el error**:

$$E[u \mid D, X] = 0$$

Eso garantiza **identificación causal**, no **correctitud del modelo funcional**.

Puedes tener:

- Identificación causal válida
- **y aun así** estimadores sesgados por **mala especificación**.

2. Qué pasa si la relación es no lineal

Si la relación verdadera es:

$$Y = f(D, X) + u$$

y estimas:

$$Y = \alpha + \beta D + \gamma X + \varepsilon$$

entonces:

- Aunque D sea exógeno (no selección),
- si $f(\cdot)$ no es lineal y no la aproximas bien,
- MCO estima **el mejor ajuste lineal**, no el efecto causal verdadero.

El sesgo aquí es de **especificación funcional**, no de selección.

3. Sobre “reducción de dimensionalidad”

MCO **no reduce dimensionalidad** en el sentido estadístico moderno.

- Incluir controles no es reducción de dimensionalidad.
- Es **condicionamiento**, no compresión.
- Si la relación es altamente no lineal o interactiva, meter X linealmente no basta.

Incluso con no selección:

- Interacciones omitidas → sesgo
- No linealidades omitidas → sesgo
- Heterogeneidad del efecto → el β es un promedio mal definido

4. Qué sí hace MCO bajo no selección

Bajo:

- exogeneidad
- forma funcional correcta

MCO identifica:

- el **efecto causal promedio marginal lineal**.

Nada más.

5. Cómo se separan bien las ideas (esto es clave)

Una forma clara de decirlo en clase o en un paper:

La ausencia de selección en no observables garantiza identificación causal, pero no garantiza que una especificación lineal capture correctamente la relación estructural subyacente.

6. Implicación práctica

Puedes tener tres escenarios:

Selección	Forma funcional	Resultado
✗	✗	basura
✓	✗	causalidad mal medida
✗	✓	correlación bien medida
✓	✓	estimación causal válida

7. Qué se hace en práctica

- Transformaciones (logs, polinomios, splines)
- Interacciones
- Métodos semiparamétricos / ML (DML, causal forests)
- Tests de especificación (RESET, análisis gráfico)

En corto, y respondiendo directamente a tu pregunta:

Sí: que MCO cumpla no selección en no observables **no garantiza** ni reducción de dimensionalidad ni ausencia de sesgo si la relación verdadera es no lineal o mal especificada. Son supuestos distintos y acumulativos, no sustitutos.

+ Pregunta lo que quieras



ChatGPT puede cometer errores. Considera verificar la información importante. Ver [preferencias de cookies](#)